# Redes Neurais Artificiais (RNA)

Prof. André Gustavo Hochuli

gustavo.hochuli@pucpr.br aghochuli@ppgia.pucpr.br github.com/andrehochuli/teaching


# Plano de Aula

- Discussões Iniciais
- Perceptron
  - Concepção
  - Pesos
  - Bias
- RNA
- Exercícios




#### **Discussões Iniciais**


- Classificação Binária vs Multi-Classes
  - One vs All
  - One vs One



#### **Redes Neurais Artificiais**


- Resolve problemas complexos
- Arquitetura é composta de neurônios artificiais conectados
- Número de Camadas é ilimitado





#### **Redes Neurais Artificiais**

Modelo Biológico vs Modelo Computacional



- Neuronio Artificial (Rosenblatt) (1958)
- Classificador Binário (0 | 1)
  - Pesos
  - Bias
  - Função de Ativação

Psychological Review Vol. 65, No. 6, 1958

#### THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN 1


#### F. ROSENBLATT

Cornell Aeronautical Laboratory

If we are eventually to understand the capability of higher organisms for perceptual recognition, generalization, recall, and thinking, we must first have answers to three fundamental questions:


- 1. How is information about the physical world sensed, or detected, by the biological system?
- 2. In what form is information stored, or remembered?
- 3. How does information contained in storage, or in memory, influence


and the stored pattern. According to this hypothesis, if one understood the code or "wiring diagram" of the nervous system, one should, in principle, be able to discover exactly what an organism remembers by reconstructing the original sensory patterns from the "memory traces" which they have left, much as we might develop a photographic negative, or translate the pattern of electrical charges in the "memory" of a digital computer. This hypothesis is appealing in its simplicity and ready intelligibility, and a large family of theoretical brain





 $x_1$   $w_1$  b  $\Sigma f$  y


Função de Ativação














- Vamos considerar uma entrada com 2 atributos (features)
  - $X_1^* W_1 + X_2^* W_2 + b$
- Considere:

• 
$$w1 = 1$$

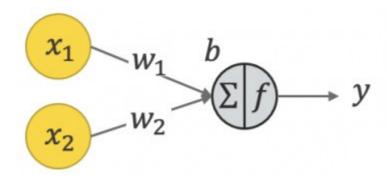
• 
$$w2 = 0$$


• 
$$w1 = 0.2$$

• 
$$w2 = 0.8$$


• 
$$b = 0$$

Ativação: Step Function






- Treinamento
  - Atualizar w1, w2 e b
  - Até que seja atingido o 'y' desejado
- · Como?
  - Loss (Função de Perda)
  - Learning Rate (Atualização dos pesos)



- Rotina de Treino
  - Inicializar pesos e bias aleatórios
  - Definir a função de ativação (exemplo: STEP Function)
  - Para cada exemplo no conjunto de treinamento:
  - a. Calcular a saída do Perceptron
  - b. Atualizar os pesos e bias com base no erro
- Rotina de Teste
  - Computar com os pesos do treino




Definição das funções básicas

```
import numpy as np


def activation(x):
    return

def predict(X,weights,bias):
    return

def fit(X, y, learning_rate=0.001, epochs=100):
    |return
```



- Fit()
  - Inicialização dos pesos




- Fit()
  - Iteração sobre a base
    - Computa o produto escalar dos pesos e bias
    - Função de Ativação
    - Perda def activation(x):
       return np.where(x >= 0, 1, 0)

```
def fit(X, y, learning_rate=0.001, epochs=100):
    n_features = X.shape[1]


# Iniacialização
    weights = weights = np.random.rand(n_features)
    bias = 0

# Iterating until the number of epochs
    for epoch in range(epochs):
        # iteração entre as amostras
        for i in range(len(X)):
            z = np.dot(X, weights) + bias # Produto escalar e bias
            y_pred = activation(z) #Função de ativação
            loss = (y[i] - y_pred[i]) #calculo da perda
```




- Fit()
  - Atualização dos pesos e bias com base no erro

```
def fit(X, y, learning rate=0.001, epochs=100):
      n features = X.shape[1]
      # Iniacialização
      weights = weights = np.random.rand(n features)
      bias = 0
      # Iterating until the number of epochs
      for epoch in range(epochs):
          # iteração entre as amostras
          for i in range(len(X)):
              z = np.dot(X, weights) + bias # Produto escalar e bias
              y pred = activation(z) #Função de ativação
              loss = (y[i] - y pred[i]) #calculo da perda
              #Atualização dos pesos com base no erro
              weights = weights + learning rate * loss * X[i]
              bias = bias + learning rate * loss
       return weights, bias
```




- Fit()
  - Criar o dataset e treinar



```
def fit(X, y, learning rate=0.001, epochs=100):
      n features = X.shape[1]
      # Iniacialização
      weights = weights = np.random.rand(n features)
      bias = 0
      # Iterating until the number of epochs
      for epoch in range(epochs):
          # iteração entre as amostras
          for i in range(len(X)):
              z = np.dot(X, weights) + bias # Produto escalar e bias
              y pred = activation(z) #Função de ativação
              loss = (y[i] - y pred[i]) #calculo da perda
              #Atualização dos pesos com base no erro
              weights = weights + learning rate * loss * X[i]
              bias = bias + learning rate * loss
         return weights, bias
```

• Predict(): Utilizar os pesos do fit e testar

```
def predict(X,weights,bias):
      z = np.dot(X, weights) + bias
      return activation(z)
#Features e Labels
X = np.array([[0, 0, 0],
              [0, 1, 0],
              [1, 1, 0],
              [1, 1, 1]])
y = np.array([1,
              1])
w,b = fit(X, y,
          learning rate=0.001,
          epochs=100)
pred = predict(X, w, b)
print(pred)
```




Link para Código Fonte


# **Redes Neurais Artificiais**

#### Relembrando


Modelo Biológico vs Modelo Computacional




- Multi-Layer Perceptron (MLP)
  - Neurônios (Perceptrons) interconectados
  - Camada de Entrada (Features)
  - Camada de Saída (Classes)
  - Otimização: Ajuste de pesos




- Multi-Layer Perceptron (MLP)
  - Não há limite de camadas e perceptrons
  - A decisão é realizada por meio de testes empíricos\*




- Feed-Forward: Computa os pesos para o o 'batch' de amostras
- Pergunta? E como determinar o erro para cada peso na rede?




- Pergunta? E como determinar o erro para cada peso na rede?
- Backpropagation
  - Regra da cadeia derivada



- Pergunta? E como determinar o erro para cada peso na rede?
- Backpropagation




- Pergunta? E como determinar o erro para cada peso na rede?
- Backpropagation
  - Regra da cadeia derivada



Quais são os parâmetros de uma MLP:


- Neurônios
- Camadas
- Ativação
- Loss
- .....
- E como definir tudo isso?
  - \*empircamente
  - Treino-Validação-Teste



- Como o nome diz, validação é uma fração da base utilizada para validar o modelo.
- Então, o teste é utilizado para avaliar a performance daquele modelo.

Existem redes que evoluiram o conceito para 'encodar'


• Sequências (LSTM, RNN)



Existem redes que evoluiram o conceito para 'encodar'


• Imagens (CNN)


#### **Convolution Neural Network (CNN)**



Existem redes que evoluiram o conceito para 'encodar'

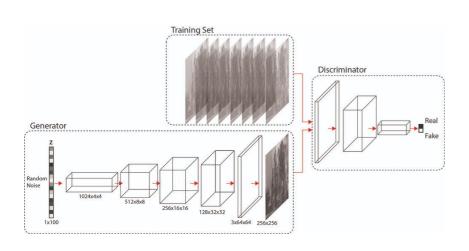
Redução (AutoEncoders)





Existem redes que evoluiram o conceito para 'encodar'

- Geração de Dados (GANs)
  - Chat-GPT
  - Deep Fakes





## **Considerações Finais**

#### Acerca de MLP

- Parametrização Complexa
- Custo Computacional Elevado
- No entanto, altamente paralelizavel
- Caixa-Preta
- Overfitting
- Atinge elevada taxas de acerto em problemas complexos
- LETS CODE! : →